

דוח פרויקט: יישום רשתות עצביות קונבולוציוניות (cnn) עם fashion-mnist

מגישי הפרויקט:

שם: דמיטרי שפק

ת.ז: 321371320

שם: אור אדר

ת.ז: 305468506

מבוא:

בפרויקט זה יישמנו רשת עצבית קונבולוציונית (cnn) לאימון והערכה על מערך הנתונים fashion-mnist. המטרה הייתה להבין את תהליך העבודה עם cnn, לבצע ניסויים עם פרמטרים שונים, ולנתח את הביצועים של המודל.

הגישה:

1. טעינת נתונים:

- השתמשנו במערך הנתונים fashion-mnist הכולל 70,000 תמונות בגווי אפור, מסווגות ל-10 קטגוריות.
- טעינת הנתונים בוצעה בעזרת מחלקות dataset ו-dataloader של pytorch.

2. עיבוד מקדים (preprocessing):

- חישבנו את ממצע וסטיית התקן של מערך הנתונים לנרמול התמונות.
- שינינו את גודל התמונות ל-32x32 כדי להתאים לקלט המודל.

3. הגברת נתונים (data augmentation):

- יישמנו היפוך אופקי וסיבוב רנדומלי כדי להגדיל את מגוון הדוגמאות באימון.

4. בניית המודל:

- יצרנו מודל cnn הכולל:
- שתי שכבות קונבולוציה
- שכבות pooling למזעור גודל התכונות.
- שכבות fully connected לסיווג.
- dropout למניעת התאמת יתר.

5. אימון המודל:

- השתמשנו באופטימיזר adam ובפונקציית האובדן croosentropyloss.
- הרצנו ניסויים עם שילובי פרמטרים שונים (epochs, learning rate, batch size, num) באמצעות random search.

6. הערכת המודל:

- מדדנו את הדיוק (accuracy) על קבוצת הבדיקה.
- יצרנו מטריצת בלבול להבנת ביצועי המודל בכל קטגוריה.

הניסויים:

במהלך הניסויים בדקנו את השפעתם של פרמטרים שונים:

1.learning rate:

- ערכים שנבדקו: [0.1, 0.01, 0.001]
- קצב למידה של 0.001 הניב את הביצועים הטובים ביותר

2.batch size:

- ערכים שנבדקו: [128, 64, 32]
- גודל מנות של 32 סיפק את הביצועים הטובים ביותר עם דיוק גבוה.

3.num epochs:

- ערכים שנבדקו: [20, 15, 10]
- 10 אפוקים היו מספקים; העלאה מעבר לכך לא שיפרה את הביצועים.

התוצאות:

1.הפרמטרים שנבדקו ותוצאותיהם:

- קצב למידה (learning rate): הוא [0.001, 0.01, 0.1]
- גודל מנות (batch size): הם [128, 64, 32]
- מספר אפוקים (num epochs): הם [20, 15, 10]

(%) Accuracy	Batch Size	Learning Rate	Num Epochs
10.00	32	0.1	20
85.31	64	0.01	15
90.54	64	0.001	10
86.56	128	0.01	10
90.95	32	0.001	10

2.הפרמטרים הטובים ביותר:

- קצב למידה: 0.001.
- גודל מנות: 32.
- מספר אפוקים: 10.
- דיוק: 90.95%.

מסקנות:

1. קצב למידה:

- קצב למידה של 0.001 הניב את הביצועים הטובים ביותר.
- קצב למידה גבוה (0.1) הוביל לדיוק גרוע מאוד (10%), ככל הנראה בגלל חוסר התכנסות.

2. גודל מנות:

- גודל מנות של 32 נתן את הדיוק הגבוה ביותר.
- גודל מנות קטן אפשר התאמות מדויקות יותר במהלך האימון.

3. מספר אפוקים:

- 10 אפוקים היו מספקים; העלאת האפוקים ל-20 לא שיפרה את הביצועים

ביצועי המודל ואתגרים:

ביצועי המודל

המודל שלנו השיג דיוק מרשים של 90.95% על קבוצת הבדיקה. תוצאות אלו משקפות את היכולת של המודל לזהות תכונות מרכזיות בנתונים, כגון קצוות, טקסטורות וצורות, ולהשתמש בהן כדי לבצע סיווג מדויק.

1. קטגוריות עם ביצועים טובים:

- פריטים מובחנים כמו נעליים ותיקים זוהו ברמת דיוק גבוהה, שכן יש להם מאפיינים חזותיים ברורים וקבועים (כגון צורה ייחודית וקווים חזקים).

2. קטגוריות עם ביצועים נמוכים:

- קטגוריות שדומות אחת לשניה, כמו חולצה ושמלה, גרמו לבלבול מסוים, מה שהוביל לדיוק נמוך יותר. המודל התקשה להפריד ביניהן בשל דמיון בתכונות מסוימות, כמו טקסטורה ומבנה.

אתגרים שנתקלנו בהם:

1. זמן ריצה:

- הרצת ניסויים עם מספר פרמטרים, במיוחד עבור שילובים גדולים, דרשה זמן רימה משמעותי, בעיקר על cpu. שימוש ב-gpu יכול היה לקצר את הזמן.

2. היפר-פרמטרים:

- מציאת פרמטרים אופטימליים הייתה מאתגרת. בעוד ש-random search אפשר חיפוש יעיל יחסית, ייתכן ששיטות מתקדמות יותר (כמו optuna) היו משיגות ביצועים טובים יותר.

3. יכולת הכללה:

- למרות הדיוק הגבוה, המודל עשוי להיאבק בנתונים שאינם חלק ממערך האימון, במיוחד אם הם מכילים פריטים בזוויות או טקסטורות יוצאות דופן.

פירוש הוויזואליזציות של פילטרים ומפות התכונות:

1. פילטרים בשכבות הראשונות:

- הפילטרים שנלמדו בשכבה הקונבולוציונית הראשונה מזהים תכונות פשוטות כנט קצוות, קווים אופקיים או אנכיים, ודפוסים בסיסיים. תכונות אלו הן היסוד לבניית הבנה מורכבת יותר בתמונות.

2. מפות תכונות (feature maps):

- בשכבות העמוקות יותר, ניתן לראות שהתכונות שהמודל מזהה הופכות ליותר אבסטרקטיות. לדוגמה:
- עבור תמונת נעל, מפות התכונות התמקדו במורה הכללית של הנעל ובחלקים ברורים כמו הסוליה.
- עבור חולצה, המודל זיהה אזורים כמו הצווארון או השרוולים.

3. השפעת פילטרים על תוצאות המודל:

- ניתן לראות שהפילטרים הראשונים בנו בסיס חזק לזיהוי תכונות, ואילו השכבות המאוירות סיווגו את הדוגמאות בהתאם לקטגוריות הנלמדות.

סיכום הניתוח:

המודל הפגין ביצועים טובים בזיהוי קטגוריות מובחנות, אך התמודד עם אתגרים בנתונים דומים. הוויזואליזציות עזרו להמחיש את התהליך שבו המודל מזהה ומנתח תכונות חזותיות כדי להגיע להחלטה.